

Juan Pablo Rosas Flores
165879

Examen Final Análisis Aplicado

December 12, 2020

1 Gradiente Conjugado

1. Demuestre que si los vectores no nulos p_1, p_2, \dots, p_l satisfacen que :

$$p_i^T A p_j = 0, \forall i \neq j,$$

y A es simétrica y positiva definida, entonces los vectores son linealmente independientes.

2. Dado este resultado, ¿Por qué el gradiente conjugado converge en a lo más n iteraciones?.

2 Quasi-Newton

1. Muestre que la segunda condición fuerte de Wolfe implica la condición de curvatura.

$$s_k^T y_k > 0.$$

2. Verifique que B_{k+1} y H_{k+1} son inversas una de la otra.

1 Gradiente Conjugado

1. Demuestre que si los vectores no nulos p_1, p_2, \dots, p_l satisfacen que :

$$p_i^T A p_j = 0, \forall i \neq j,$$

y A es simétrica y positiva definida, entonces los vectores son linealmente independientes.

2. Dado este resultado, ¿Por qué el gradiente conjugado converge en a lo más n iteraciones?.

1. Por la hipótesis asumimos que los vectores p_1, p_2, \dots, p_l son conjugados, ahora bien, supongamos que no son linealmente independientes, entonces podemos escribir

$p_i = \sum_{k \neq i} \sigma_k p_k$, es decir, escribir al i -ésimo como una comb. lineal de los demás. Ahora multiplicamos por izquierda a $p_j^T A$ para cualquier $j \neq i$, y de esta forma:

$$\begin{aligned} 0 &= p_j^T A p_i = p_j^T A \sum_{k \neq i} \sigma_k p_k \\ &= \sigma_1 \cancel{p_j^T A p_1} + \sigma_2 \cancel{p_j^T A p_2} + \dots + \sigma_j p_j^T A p_j + \dots + \sigma_l \cancel{p_j^T A p_l} \end{aligned}$$

$$\Rightarrow \forall j \neq i \text{ tenemos que : } 0 = \sigma_j p_j^T A p_j$$

* por ser conjugados

$$\text{y como } A \text{ es posit. def: } p_j^T A p_j > 0 \Rightarrow \sigma_j = 0$$

\therefore Si $\forall j \neq i$ $\sigma_j = 0$ tenemos que

$$p_i = \sum_{k \neq i} \sigma_k p_k = 0 \quad \nabla \text{ pues los } p_i \text{'s son no-nulos.}$$

\therefore Si son l.i. pues al suponer lo contrario llegamos a un absurdo //

2.- Por el inciso anterior dado que los $\{P_i\}$ son l.i.,
 $\mathbb{R}^n \subseteq \text{span} \{P_i\}$, queremos ver que $\{x_k\} \rightarrow x^*$ en máx. n iteraciones
 donde $x_0 \in \mathbb{R}^n$, x^* es la sol. óptima.

$$\Rightarrow x^* - x_0 = \sigma_0 P_0 + \sigma_1 P_1 + \dots + \sigma_{n-1} P_{n-1} \text{ para algunos } \sigma_k$$

$$\Leftrightarrow P_k^T A (x^* - x_0) = P_k^T A (\sigma_0 P_0 + \sigma_1 P_1 + \dots + \sigma_{n-1} P_{n-1})$$

$$\text{y por hipótesis } P_i^T A P_j = 0 \quad \forall i \neq j$$

$$\Rightarrow \sigma_k = \frac{P_k^T A (x^* - x_0)}{P_k^T A P_k}, \text{ y } x_{k+1} = x_k + \alpha P_k$$

$$\text{y } \min \phi = Ax - b = r(x) \Rightarrow r_k = Ax_k - b$$

$$\Rightarrow \alpha_k = \frac{-r_k^T P_k}{P_k^T A P_k}$$

$$\text{y al usar } x_k = x_0 + \sigma_0 P_0 + \sigma_1 P_1 + \dots + \sigma_{k-1} P_{k-1} :$$

$$P_k^T A (x_k - x_0) = 0 \Rightarrow P_k^T A (x^* - x_0) = P_k^T A (x^* - x_k) = -P_k^T P_k$$

con $\sigma_k = \alpha_k$ vemos que máx. en n iteraciones
 se converge //

2 Quasi-Newton

1. Muestre que la segunda condición fuerte de Wolfe implica la condición de curvatura.

$$s_k^T y_k > 0.$$

2. Verifique que B_{k+1} y H_{k+1} son inversas una de la otra.

1. La segunda condición fuerte de Wolfe nos dice que

$$(1) \quad |\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c |\nabla f(x_k)^T p_k| \quad 0 < c < 1$$

$\Leftrightarrow \nabla f(x_k + \alpha_k p_k)^T p_k \geq -c |\nabla f(x_k)^T p_k|$, pero como p_k es dirección de descenso:

$$\Leftrightarrow \nabla f(x_k + \alpha_k p_k)^T p_k = c \nabla f(x_k)^T p_k$$

$$(2) \quad \Leftrightarrow \nabla f(x_k + \alpha_k p_k)^T p_k - \nabla f(x_k)^T p_k = (c-1) \nabla f(x_k)^T p_k > 0 \quad \text{pues } c-1 < 0$$

Ahora bien, $y_k = \nabla f(x_k + \alpha_k p_k) - \nabla f(x_k) \quad \wedge \quad s_k = \alpha_k p_k$

\therefore si a (2) le mult. α_k tenemos:

$$\nabla f(x_k + \alpha_k p_k)^T \alpha_k p_k - \nabla f(x_k)^T \alpha_k p_k = (c-1) \nabla f(x_k)^T \alpha_k p_k > 0$$

y al sustituir $s_k = \alpha_k p_k$:

$$(\nabla f(x_k + \alpha_k p_k)^T - \nabla f(x_k)^T) s_k = (c-1) \nabla f(x_k)^T s_k > 0$$

y al sustituir $y_k = \nabla f(x_k + \alpha_k p_k) - \nabla f(x_k)$:

$$(y_k)^T s_k > 0 \quad \Leftrightarrow \quad s_k^T y_k > 0 \quad //$$

2.- tenemos: (1) $B_{k+1} = B_k - \frac{B_k S_k S_k^T B_k}{S_k^T B_k S_k} + \frac{y_k y_k^T}{y_k^T S_k} = B_k - \frac{B_k S_k S_k^T B_k}{S_k^T B_k S_k} + \rho_k y_k y_k^T$

(2) $H_{k+1} = (I - \rho_k S_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k S_k S_k^T$

con $\rho_k = \frac{1}{y_k^T S_k}$

$$B_{k+1} H_{k+1} = B_{k+1} \left[(I - \rho_k S_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k S_k S_k^T \right]$$

$$= (B_{k+1} - \rho_k y_k y_k^T) H_k (I - \rho_k y_k S_k^T) + \rho_k y_k S_k^T$$

$$= \left(I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \right) (I - \rho_k y_k S_k^T) + \rho_k y_k S_k^T$$

$$= I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} - \rho_k y_k S_k^T + \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \rho_k y_k S_k^T = I //$$

$\therefore H_{k+1}$ y B_{k+1} son inversas. entesi'